

机器学习核心知识点总结

姓名：王善义

学号：202321054048

本次作业核心内容



核心阅读材料

精读《参考教材1》的关键章节，重点掌握第1-2章的基础理论与4-5章的进阶知识；同时研读《白话机器学习算法》，通过通俗案例加深对复杂算法的理解与认知。



核心执行任务

系统梳理阅读过程中的思考与感悟，形成结构化的读书笔记；同时抽丝剥茧，提炼并汇总机器学习领域的核心概念、模型框架与关键应用场景，构建完整的知识图谱。



内容呈现原则

坚持“少而精”的原则，摒弃冗余信息，聚焦最关键的知识点与核心逻辑；以清晰、直观的方式呈现内容，确保信息传递高效，让读者能快速抓取核心价值与关键点。

总结：以核心资料为基石，以概念汇总为核心，以精简表达为手段，完成从知识输入到认知输出的闭环构建。

《白话机器学习算法》核心笔记

01 主流分类方法全景 (7种核心算法)

基础经典：最近邻(KNN)、贝叶斯、决策树、判别分析。这四类是理解分类逻辑的基石，原理直观易懂。

进阶前沿：逻辑斯蒂回归、支持向量机(SVM)、神经网络。适用于复杂数据分布，在现代AI应用中广泛使用。

02 K-近邻 (KNN) 算法核心解析

💡 核心思想


“近朱者赤，近墨者黑”，通过样本邻居的类别来判断自身类别，完全基于数据相似性。

🔄 执行三步

计算距离→选定K个最近邻→多数表决投票。步骤简单直接，易于理解和实现。


⚙️ K值权衡

K太小易过拟合，受噪声干扰；K太大易欠拟合，模型粗糙，需交叉验证调优。



图示：不同K值对分类结果的影响。当K=5时，查询点被分为Class 2；当K=7时，则被分为Class 1。直观展示了K值是如何决定决策边界的形状的。

参考教材重点提炼(一)



机器学习三大范式


涵盖监督、无监督与强化学习，构成了现代AI算法的核心基础，分别解决预测、模式发现与决策优化问题。

01 监督学习

利用带标签数据训练模型，核心用于预测与分类任务，是应用最广泛的学习范式。

02 无监督与强化学习

无监督学习从无标签数据中挖掘隐藏模式，如聚类；强化学习则通过环境交互与奖励反馈优化行为策略。



K-Means 聚类算法

经典的无监督学习算法，通过迭代更新簇中心实现数据分组，是数据探索与预处理的重要工具。

核心思想与原理

将数据划分为K个簇，使每个数据点都归属于距离其最近的簇中心，通过最小化簇内误差平方和实现收敛。

关键适用场景

最适合处理特征空间中呈正圆形、紧密且非重叠的球状数据群组，对异常值较为敏感，需预处理优化。

参考教材重点提炼(二)

01. 关联规则三大核心评价指标

支持度衡量项集出现频率，置信度体现规则可靠性，提升度则反映规则的实际强度与相关性，三者结合才能全面评估关联规则的价值。

02. 决策树与随机森林：从单一到集成

决策树直观易解释但易过拟合；随机森林通过集成多棵决策树并采用投票机制，显著提升了预测准确率，同时有效缓解了过拟合问题。

03. 模型偏差与方差的权衡

过拟合是模型“太敏感”，对训练数据过度学习；欠拟合则是模型“太愚钝”，未能捕捉数据规律。建模的核心是寻找两者间的平衡点。




图1：随机森林集成模型示意
通过多棵决策树的投票机制进行分类预测，有效提升模型鲁棒性。




图2：拟合状态对比
从欠拟合到正常拟合再到过拟合的模型表现变化。理想模型应贴合数据趋势，而非噪声。

核心算法汇总表

算法类型	代表算法	核心思想	适用场景
聚类	K均值 (K-means)	基于距离最近原则将相似数据点自动划分到不同簇中，使簇内相似度高，簇间相似度低。	客户分群画像、用户行为聚类、市场细分、文档主题聚类等无监督场景。
关联	Apriori	通过逐层迭代挖掘数据中的频繁项集，进而发现数据项之间隐含的关联规则与内在联系。	电商购物篮分析、商品组合推荐、网页链接点击分析、医疗诊断关联规则挖掘。
分类	K近邻 (KNN)	基于“近朱者赤”思想，依据样本最近邻的K个样本的多数类别来表决该样本的所属类别。	数据量较小、特征维度低的简单分类场景，如图像初步分类、手写数字识别原型验证。
分类	决策树	通过递归地选择最优特征拆分数据集，生成树状结构的决策规则，实现对样本的分类。	需要高可解释性的业务场景，如信贷风险评估、医疗辅助诊断、规则明确的业务判断。
分类	随机森林	构建多棵决策树并通过投票机制集成结果，有效降低过拟合风险，提升模型整体准确率。	处理复杂、高维度数据且要求高准确率的场景，如金融欺诈检测、精准营销、图像识别。

核心概念汇总



01. 数据准备：构建可靠基石

通过特征工程提取、转换并创建关键特征；采用删除或填充策略处理缺失值；利用科学方法筛选对模型最有价值的变量，为后续建模筑牢数据基础。



02. 模型训练：科学验证流程

将数据集严格划分为训练集与测试集，确保评估的客观性；引入交叉验证方法，通过多轮次的训练与测试，有效降低随机误差，获得更可靠的模型性能评估结果。



03. 参数调优：优化模型泛化

核心在于引入正则化惩罚项，限制模型复杂度以防止过拟合；同时结合减少冗余特征、增加训练数据量等策略，平衡模型的拟合能力与泛化能力，提升鲁棒性。



04. 模型评价：多维指标体系

		实际标签	
		错误	正
预测	错误	400	10
	正确	100	40

分类任务关注准确率、混淆矩阵等；回归任务侧重RMSE、MAE及 R^2 指标。通过科学的评价体系，量化模型表现，精准定位优势与不足。

总结

机器学习四步骤

1. 准备数据：清洗、标注与特征工程，夯实基础。
2. 建模调优：选择算法，迭代调整参数以优化表现。
3. 评价模型：通过测试集验证，确保模型的有效性。

核心思想：寻找平衡

算法的本质，是在模型的复杂度与泛化能力之间寻找最佳平衡点。避免过拟合导致模型僵化，同时防止欠拟合无法捕捉数据规律，实现适用性与准确性的统一。

实践路径建议

坚持“从简到繁”的原则：先用简单算法快速探索数据分布与特征关系，再逐步引入复杂模型追求更高精度，循序渐进，稳步提升。

回归分析作业

数据挖掘与机器学习

姓 名：王善义

学号：202321054048

目录

01. 回归分析基本方法与步骤

系统梳理回归分析的核心逻辑，从问题提出、数据收集到模型构建、检验优化的完整流程。

02. 一元线性回归数学模型

解析单一自变量与因变量的线性关系，推导最小二乘估计参数，建立基础的预测与解释模型。

03. 多元线性回归数学模型

扩展至多变量场景，分析多重共线性、偏回归系数的意义，构建更贴合复杂现实的预测体系。

04. Logistic回归数学模型

针对分类问题，通过Sigmoid函数将输出映射至 $[0,1]$ 区间，构建概率型非线性回归模型。

05. Logistic回归与线性回归的比较

对比两种模型的适用场景、假设条件与参数估计方法，厘清线性预测与概率分类的本质差异。

06. 《白话机器学习》读书笔记

结合经典科普读物，提炼回归分析的直观理解与实战启示，探讨模型在实际业务中的应用价值。

回归分析基本方法与步骤

回归分析旨在处理变量间的相关关系，探究当一个或多个自变量(X)发生变化时，因变量(Y)随之产生的变动规律，是量化分析变量依存关系的核心统计方法。

01 函数关系：确定性的——对应

变量间存在严格确定的数学关系，当自变量取定值后，因变量的值唯一确定。例如：圆的面积公式 $S = \pi r^2$ ，给定半径 r 即可精确计算面积 S 。

02 相关关系：非确定的依存关联

变量间存在某种依存趋势，但并非严格——对应。例如：身高与体重的关系，通常身高较高者体重较重，但相同身高的人，体重却存在个体差异，受其他因素影响。

01 收集数据

系统采集因变量Y与自变量X的观测样本，确保数据的代表性与完整性。

02 模型设定

根据理论或经验选择回归模型形式，并运用估计方法计算模型的参数系数。

03 模型评估

通过拟合优度、显著性检验等统计指标，评估模型对数据的解释能力并筛选最优模型。

04 模型诊断

检验模型假设（如线性、正态性等）是否满足，判断模型的适用性与稳健性。

05 模型应用

利用最终确定的模型进行预测分析，或解释变量间的内在数量关系与经济意义。

一元线性回归数学模型

01. 基本模型形式

$$y = \beta_0 + \beta_1 x + \varepsilon$$

其中， y 为因变量， x 为自变量， β_0 为截距项， β_1 为斜率系数， ε 为随机误差项，代表模型未能解释的随机因素。

02. 核心思想：最小二乘准则


寻找一条最佳拟合直线，使得所有观测数据点到该直线的垂直距离（残差）的平方和达到最小，以此确定参数 β_0 和 β_1 的最优估计值。

参数估计方法

采用普通最小二乘法(OLS)，通过最小化残差平方和求解回归系数，是最经典的线性估计方法。

拟合优度评估

使用决定系数 R^2 衡量，取值在0到1之间，反映了因变量的变异中可以被自变量解释的比例。



图示展示了一元线性回归的拟合过程：红色直线为根据最小二乘法拟合出的最优回归线，蓝色散点为实际观测数据。回归线尽可能穿过数据的中心，以最小化所有点到直线的垂直距离平方和。

多元线性回归数学模型




图1：二元自变量下的多元线性回归平面拟合示意图，展示了因变量与两个自变量间的线性关系。

基本数学形式：

$$y = \beta_0 + \beta_1x_1 + \beta_2x_2 + \dots + \beta_px_p + \varepsilon$$

☞ 核心特点

引入多个自变量共同构建模型，能够更全面地捕捉影响因变量y的复杂因素，显著提升模型的解释力。

📊 偏回归系数

β_j 代表在控制其他自变量不变时，自变量 x_j 每变化一个单位，因变量y的平均变化量，即边际影响。

⚙️ 核心优势

能够有效控制混淆变量的干扰，剥离无关因素的影响，从而更准确地推断自变量与因变量间的真实因果关系。



关键提示：不同自变量的测量单位通常不同，直接比较系数大小无实际意义，需先对数据进行标准化处理后再分析。

Logistic回归数学模型

01. 核心适用场景

主要用于二分类问题，即因变量Y是一个取值仅为0或1的离散分类变量，如判断事件“发生”与“不发生”、样本“属于A类”与“属于B类”。

02. 映射工具：Sigmoid函数

通过Sigmoid函数将线性组合结果压缩至[0,1]区间，以表示事件发生的概率：

$$p = P(Y=1|X) = 1 / (1 + e^{-(\beta_0 + \beta_1 x_1 + \dots + \beta_p x_p)})$$

因变量类型


必须是二元分类变量，取值严格为0或1，代表互斥的两种状态。

输出概率范围

模型输出结果为事件发生的概率值，范围在0到1之间，阈值通常取0.5。

参数估计方法

采用极大似然估计(MLE)来求解最优参数，使观测样本出现的概率最大化。



图示为Sigmoid函数曲线，其S型形态完美实现了从实数域到概率区间[0,1]的非线性映射，是Logistic回归模型的核心数学基础。

Logistic回归与线性回归比较

01. 因变量类型

线性回归针对连续变量，如股价、气温等；Logistic回归则处理分类变量，最常见的是二分类问题（如患病与否、用户流失）。

02. 输出范围与参数估计


线性回归输出为 $(-\infty, +\infty)$ 的实数，采用最小二乘法(OLS)拟合；Logistic回归输出 $[0,1]$ 的概率值，通过极大似然估计(MLE)求解最优参数。

03. 核心数学函数

线性回归基于线性方程 $y = \beta X$ 描述变量关系；Logistic回归引入Sigmoid函数 $p = 1 / (1 + e^{(-\beta X)})$ ，将线性结果映射为概率，解决分类边界问题。

《白话机器学习》核心启示

回归分析的本质是“找一条最能代表数据趋势的线”。多变量组合预测通常比单变量更准确，因为现实问题往往受多重因素共同影响。



梯度下降法的直观理解

这是一种迭代优化算法，过程如同从山上寻找最低点。通过不断调整参数，沿着代价函数梯度的反方向一步步“下山”，最终收敛到最优解。

小结

01 / 核心定位

回归分析是处理变量间相关关系、进行预测和解释的核心统计方法，是探索数据内在规律与因果关联的基础工具。

02 / 模型选择与适配

线性回归适用于连续值预测任务；Logistic回归则针对分类值（尤指二分类）场景。需根据因变量的类型特征，精准匹配模型以确保分析有效性。

03 / 正确应用的关键

透彻理解不同回归模型的基本假设（如线性关系、独立性、方差齐性等）和适用条件，是避免模型误用、保证结论可靠性的核心前提。

04 / 进阶算法基石

梯度下降等优化算法不仅支撑回归模型的参数求解，更是理解神经网络、支持向量机等更复杂现代机器学习算法的重要理论与实践基础。



南京工业大学
NANJING TECH
UNIVERSITY

数据挖掘与机器学习

Classification algorithm

姓名：王善义

学号：202321054048

2026年3月24日

目录

CONTENTS

01

分类算法的基本逻辑与核心概念

Basic Logic and Core Concepts of Classification Algorithms

02

KNN算法的核心思想与算法步骤

Core Idea and Algorithm Steps of the KNN Algorithm

03

k最近邻算法和异常检测——读书笔记

k-Nearest Neighbor Algorithm and Anomaly Detection — Reading Notes

04

决策树——读书笔记

Decision Tree — Reading Notes



南京工业大学
NANJING TECH
UNIVERSITY

01

PART ONE


分类算法的基本 逻辑与核心概念

Basic Logic and Core Concepts of
Classification Algorithms

► 算法本质 源自课件P4-P5

对现有的数据进行学习，得到一个目标函数或模型（**分类器**），该模型能把未知类别的样本映射到给定的类别中。

► 分类、聚类算法对比





完整执行流程

源自《白话机器学习》1.4.3节
验证

1.4.3 验证

指标并不能完整地体现模型的性能。过拟合模型（有关内容请参考 1.3 节）在面对当前数据时表现良好，但是在面对新数据时可能表现得很糟糕。为了避免出现这种情况，必须使用合适的验证过程对模型进行评价。

验证是指评估模型对新数据的预测准确度。然而，在评估模型时，并不一定要使用新数据，而是可以把当前的数据集划分成两部分：一部分是训练集，用来生成和调整预测模型；另一部分是测试集，用来充当新数据并评估模型的预测准确度。最好的模型，针对测试集所做的预测一定是最准确的。为了使验证过程行之有效，需要不带偏差地把数据点随机分派到训练集和测试集中。

然而，如果原始数据集很小，可能无法留出足够的数据来形成测试集，因为当用于训练模型的数据较少时，准确度无法得到保障。为了解决这个问题，有人提出了交叉验证这个方法：使用同一个数据集进行训练和测试。

交叉验证最大限度地利用了可用的数据，它把数据集划分成若干组，用来对模型进行反复测试。在单次迭代中，除了某一组以外，其他各组都被用来训练预测模型；然后，留下的那组被用来测试模型。这个过程重复进行，直到每一组都测试过模型，并且只测试过一次，如图 1-3 所示。

模型训练

用学习算法对训练集做归纳
学习，生成分类器模型

模型验证

用测试集检验模型的预测准
确率，评估泛化能力

数据拆分

将带类标签的原始数据集，
拆分为训练集和测试集

执行流程

模型应用

将验证通过的分类器，应用
到无标签的新数据中，完成
分类预测



► 分类算法核心概念

源自课件P6

分类器

能解释原始数据、对新数据完成类别预测的模型，是分类算法的核心输出

类标签

原始数据中，为每条记录预先标记好的类别归属，是模型学习的“标准答案”

训练集

从原始数据中拆分出、专门用于训练分类器的数据集

测试集

从原始数据中拆分出、专门用于测试模型准确率、检验泛化能力的数据集

开放集

模型训练完成后，实际应用中需要分类预测的无标签新数据

► 评价核心概念

源自课件P15


核心是**混淆矩阵**，用于直观展示模型预测结果与真实结果的匹配情况，衍生出核心评价指标：





► 衍生评价指标

源自课件P16



01

精确率

$$Precision = \frac{TP}{TP+FP}$$

预测为正例的结果中，真正为正例的比例，重点降低误报

02

召回率

$$Recall = \frac{TP}{TP+FN}$$

真实为正例的样本中，被模型正确预测的比例，重点降低漏报

03

F1值

$$F1 = \frac{2 \times Precision \times Recall}{Precision + Recall}$$

精确率和召回率的调和平均数，综合平衡模型性能



南京工業大學
NANJING TECH
UNIVERSITY

02

PART TWO

KNN算法的核心思想与 算法步骤

Core Idea and Algorithm Steps of the KNN Algorithm



► KNN算法核心思想

源自课件P9、P11

KNN是最简单的、纯基于**数据经验**的分类算法，核心逻辑为物以类聚，人以群分。

核心假设：数据集中特征相似的样本，在特征空间中的距离也会相近；判断一个未知样本的类别，只需看离它最近的 K 个「邻居」，哪个类别占多数，就把它归为这个类别。

距离度量

计算待分类样品到训练集中每一个样例的空间距离

类别统计

统计 K 个样例中，各个类别的出现频次与占比

算法步骤

选取近邻

按照距离从小到大排序，选取和待分类样品距离最近的 K 个训练样例，作为参考邻居

投票决策

K 个样品中哪个类别的训练样例占多数，待分类样品就属于哪个类别

► KNN算法补充要点

源自课件P17



◀ K值的选择是核心

K 值过小：模型只参考极近的样本，容易放大数据随机噪声，导致过拟合，泛化能力差

K 值过大：模型会参考过远的不相关样本，忽略数据核心模式，导致欠拟合，预测准确率下降

最优 K 值确定方法：交叉验证法；二分类问题常选奇数 K 值，避免投票出现平局

◀ 算法特点

优点：只与极少量的相邻样本有关，可较好地避免样本不平衡问题；原理简单、易于理解，无复杂的训练过程

缺点：需要计算新样本到所有已知样本的距离，算法计算量大、复杂度高；对高维数据、冗余特征敏感



南京工业大学
NANJING TECH
UNIVERSITY

03

PART THREE

k最近邻算法和 异常检测——读 书笔记

k-Nearest Neighbor Algorithm and Anomaly
Detection — Reading Notes



► 章节概述

本章以 红白葡萄酒区分为核心案例，从 0 到 1 讲解了 k 最近邻算法的核心原理、参数选择、实际应用，同时延伸了算法在异常检测场景的拓展用法，最后完整分析了算法的局限性与适用场景。以直观案例讲透算法本质。

源自《白话机器学习》P34

7.1 食品检测

让我们来聊聊葡萄酒。你是否曾想真正地搞清楚红葡萄酒和白葡萄酒的区别？

有些人想当然地认为，红葡萄酒是用红葡萄酿制的，而白葡萄酒是用白葡萄酿制的。但是这并非完全正确，尽管红葡萄酒不能用白葡萄酿制，可白葡萄酒是可以用红葡萄酿制的。

红白葡萄酒最大的区别在于葡萄的发酵方式不同。酿制红葡萄酒时，葡萄汁和葡萄皮是混在一起发酵的，葡萄皮在这个过程中会释放出独特的红色素。酿制白葡萄酒时，则要把葡萄皮去掉，只发酵葡萄汁。

一方面，我们可以根据葡萄酒的颜色推断其酿制过程有无用到葡萄皮；另一方面，葡萄皮会导致葡萄酒的化学成分发生变化，这意味着不用观察葡萄酒的颜色，只通过分析化学成分的含量就能推断出葡萄酒的颜色。

为了检验这个假设，可以使用机器学习中最简单的一种方法：□ 最近邻算法。



► 核心原理

分类核心逻辑

- KNN 算法根据周围数据点的类型对某个数据点进行分类，K 表示用作参考的邻居数据点个数。
- 除分类外，KNN 还可通过合计周围数据点的加权平均值，预测连续值，距离越近的邻居权重越大。

01

参数调优核心

- K 值的选择直接决定模型效果，K 值过小易过拟合，K 值过大易欠拟合，需通过交叉验证法确定最优 K 值。

02

异常检测延伸应用

- KNN 的预测误差能直接反映数据点与整体数据模式的匹配度，预测错误的数据点会被标记为潜在异常，可用于欺诈检测、数据质控等场景；识别并移除异常数据，可进一步提升模型预测准确度。

03

► 分类核心

k 值太小:

数据点只与最近的「邻居」匹配，随机噪声产生的误差会被放大，出现过拟合问题

k 值太大:

数据点会尝试与更远的「邻居」匹配，数据中隐含的模式会被忽略，出现欠拟合问题

最优 k 值:

只有 k 值恰到好处时，数据点才会参考合适数量的「邻居」，让误差相互抵消，揭示数据中隐藏的趋势；最优 k 值需通过交叉验证法确定；二分类问题常把 k 设置为奇数，避免投票出现平局




图 7-2 使用不同的 k 值进行拟合。黑色区域中的点被预测为白葡萄酒，红色区域中的点则被预测为红葡萄酒

如果 k 值太小，数据点只与最近的“邻居”匹配，并且随机噪声所产生的误差也会被放大，如图 7-2a 所示。如果 k 值太大，数据点会尝试与更远的“邻居”匹配，其中隐含的模式会被忽略，如图 7-2c 所示。

只有当 k 值恰到好处时，数据点才会参考合适数量的“邻居”，这使得误差相互抵消，有利于揭示数据中隐藏的趋势，如图 7-2b 所示。

为实现理想拟合并把误差降到最低，可以使用交叉验证法对参数 k 进行调优（请参考 1.4.3 节）。对于二分类问题，可以把 k 设置成一个奇数，以避免出现平局的情况。

除了用来为数据点分类， k 最近邻算法还可以通过合计周围数据点的值来预测连续值。相比于平等看待周围的所有数据点并简单地取平均值，通过使用加权平均值，能够进一步改善预测结果。离数据点越近的“邻居”，其值越能反映该数据点的真实值，因此赋给它的权重应该更大。

► 参数调优核心

课本以葡萄牙青酒数据集为基础，用 1599 种红葡萄酒、4898 种白葡萄酒的化学成分数据，验证了 k 最近邻算法的分类效果：

核心特征选择：

选取「氯化物含量」和「二氧化硫含量」两个核心化学成分作为分类特征

数据规律：

红葡萄酒因葡萄皮参与发酵，氯化物含量更高，集中在图表右下部分；
白葡萄酒需要更多二氧化硫做防腐剂，集中在图表左上部分

算法效果：

在理想拟合的情况下，k 最近邻算法推断葡萄酒颜色的准确率超过 98%

回到葡萄酒的例子。通过观察与之有相似化学成分的葡萄酒，可以猜出某款葡萄酒的颜色。

如图 7-3 所示，我们利用葡萄牙青酒的各种红白变种酒的数据把 1599 种红葡萄酒和 4898 种白葡萄酒的化学成分绘制了出来，图中涉及两种化学成分，即氯化物（横轴）和二氧化硫（纵轴）。




图 7-3 白葡萄酒（黑点）和红葡萄酒（红点）中氯化物和二氧化硫的含量

因为葡萄皮中的矿物质（比如氯化钠，与食盐成分一样）含量较高，所以红葡萄酒中这些成分的含量就相对较高，图中很好地反映出了这一点。葡萄皮还含有天然抗氧化剂，用来使葡萄保持新鲜。白葡萄酒不包含这种成分，所以需要使用更多的二氧化硫来充当防腐剂。正是这些原因使得红葡萄酒大都集中在图中的右下部分，白葡萄酒则主要集中在左上部分。



► 异常检测

课本明确了 k 最近邻算法的拓展能力：除分类和连续值预测外，还可用于异常检测（如欺诈行为检测）。

核心逻辑：

k 最近邻算法依靠数据中的隐藏模式做预测，如果出现预测误差，就说明数据点和总体趋势不一致；事实上，任何能生成预测模型的算法，都可以用来检测异常。

异常数据的价值：

分析分类错误的异常数据，能发现被忽略的关键预测变量。比如被错划成白葡萄酒的红葡萄酒，大多含有较多二氧化硫，原因是其酸度较低，需要更多二氧化硫防腐；基于这个发现，加入「酸度」变量，能进一步提升模型预测准确度。

数据优化方法：

找到异常数据点后，将其从数据集中移除，再训练预测模型，可减少数据噪声，大幅提升模型准确度。

7.4 异常检测

最近邻算法不仅可以用来预测数据点的类别和取值，还可以用来识别异常，比如检测欺诈行为。而且，在异常检测过程中还可能会有新的发现，比如发现之前被忽略的预测变量。

数据可视化让异常检测变得简单。比如在图 7-3 中，我们能一眼看出哪些酒偏离了它们所属的群组。不过，并非所有数据都可以用二维图表示，尤其是当要检查的预测变量超过两个时，更是如此。这正是最近邻等预测模型大显身手的时候。

因为最近邻算法利用数据中的隐藏模式做预测，所以如果出现预测误差，就说明数据点和总体趋势不一致。事实上，任何能够产生预测模型的算法都可以用来检测异常。比如，在回归分析中，如果某个数据点明显偏离最佳拟合线，那么就会被识别为异常点。

稍微分析一下葡萄酒颜色归类错误时的异常数据，就会发现那些被错划成白葡萄酒的红葡萄酒往往含有较多的二氧化硫。由于这些葡萄酒的酸度较低，因此需要更多的二氧化硫来充当防腐剂。如果知道了这一点，那么我们可能会把葡萄酒的酸度也考虑进去，从而进一步提高预测的准确度。

异常数据点既可能因缺失预测变量所致，也可能因预测模型缺少足够的训练数据所致。我们拥有的数据点越少，就越难发现隐藏于数据中的模式，所以务必确保建模时有足够的样本可用。

一旦找到异常数据点，就要将它们从数据集中移除，然后再训练预测模型。这样做可以减少数据中包含的噪声，进而提高模型的准确度。

▶ 算法局限性

◀ 类别不平衡

如果待预测的多个类别，在样本大小上存在很大差异，最小类别的数据点可能会被更大类别的数据点掩盖，被错误分类的风险更大。

◀ 预测变量多

如果待考虑的预测变量太多，在多个维度上识别和处理近邻会导致计算量大增；且多余的预测变量，对提升预测准确度没有帮助。

7.5 局限性

尽管  最近邻算法简单且实用，但是在如下情形中使用该算法可能无法取得好的效果。

- **类别不平衡**：如果待预测的类别有多个，并且在大小方面存在很大的不同，那么那些属于最小类别的数据点可能会被来自更大类别的数据点所掩盖，它们被错误分类的风险更大。为了提高准确度，可以使用加权投票法来取代少数服从多数的原则，这会确保较近数据点类别的权重比较远的更大。
- **预测变量过多**：如果待考虑的预测变量太多，在多个维度上识别和处理近邻会导致计算量大增。而且，有些预测变量可能是多余的，它们对提高预测准确度没有用处。为了解决这个问题，可以使用第 3 章介绍的降维技巧，只抽取最具影响力的预测变量用于分析。



南京工业大学
NANJING TECH
UNIVERSITY

04

PART FOUR

决策树——读书笔记

Next step work plan

► 章节概述

本章以泰坦尼克号灾难幸存者预测为核心案例，讲解了决策树算法的核心逻辑、树形结构、生成方法，同时分析了算法的核心优势与天然缺陷，最后引出了随机森林等集成算法的优化方向。全章核心突出决策树极致的可解释性。

9.2 示例：逃离泰坦尼克号

为了说明如何通过决策树预测乘客生还概率，我们选用了由英国贸易委员会整理的泰坦尼克号乘客数据，用以判断什么样的乘客生还的可能性更大。图 9-2 展示了使用决策树预测乘客生还概率的情况。




图 9-2 使用决策树判断一个人能否逃离泰坦尼克号



► 核心原理

分类核心逻辑

- KNN 算法根据周围数据点的类型对某个数据点进行分类，K 表示用作参考的邻居数据点个数。
- 除分类外，KNN 还可通过合计周围数据点的加权平均值，预测连续值，距离越近的邻居权重越大。

01

参数调优核心

- K 值的选择直接决定模型效果，K 值过小易过拟合，K 值过大易欠拟合，需通过交叉验证法确定最优 K 值。

02

异常检测延伸应用

- KNN 的预测误差能直接反映数据点与整体数据模式的匹配度，预测错误的数据点会被标记为潜在异常，可用于欺诈检测、数据质控等场景；识别并移除异常数据，可进一步提升模型预测准确度。

03

► 生成决策树算法核心原理

核心生成逻辑

先根据相似性把所有数据点分为两组，然后针对每组重复这个二分过程；每一层叶节点都比上一层包含更少的数据点，但同质性更高。

通用终止条件

- 1、每个叶节点中的数据点全属于同一类或有相同的值
- 2、叶节点包含的数据点少于 5 个
- 3、进一步分支会超出阈值并且不能提高同质性

生成决策树

递归拆分


步骤 1：确定一个二元选择题，它能够把数据点拆分为两组，并最大限度地提高每组数据点的同质性。

步骤 2：针对每个叶节点重复步骤 1，直到满足终止条件。

算法优势


- 1、极度易于解释，树形结构完全可视化，每一步判断逻辑都清晰可追溯
- 2、对异常值有较强的耐扰性，不显著的变量不会影响最终结果
- 3、递归拆分只用最佳二元选择题生成决策树，自动忽略不显著的变量，无需复杂的特征预筛选

▶ 算法局限性



模型不稳定

决策树通过数据点分组生成，数据中的细微变化可能影响拆分结果，导致生成的决策树截然不同；且每次拆分都追求当下最佳拆分方式，极易产生过拟合问题。



局部最优！ = 全局最优

一开始就使用最佳二元选择题拆分数据点，并不能保证最终结果最准确；有时先用不太有效的分法，反而会产生更好的预测结果。



优化方案

随机森林： 随机选择不同的二元选择题，生成多棵决策树，综合所有决策树的预测结果

梯度提升： 有策略地选择二元选择题，逐步提高决策树的预测准确度，将所有预测结果的加权平均数作为最终结果



南京工业大学
NANJING TECH
UNIVERSITY

感谢您的观看！

姓名：王善义

学号：202321054048

2026年3月24日

聚类算法作业

数据挖掘与机器学习

姓名：王善义 | 学号：202321054048

作业说明



01. 整理簇的核心概念

研读教材Jp187-188内容，剖析聚类的本质内涵，厘清“簇”作为数据集合的核心特征与定义边界。



02. 梳理核心距离度量方式

参考教材Jp189-190，重点掌握欧式距离与余弦距离的数学原理，对比两种度量方法在不同数据场景中的适用差异。



03. 解析K-means算法原理与步骤

结合教材Jp192内容，拆解K-means算法的初始化、分配、更新、收敛全流程，理解其核心迭代机制与实现逻辑。



04. 梳理层次聚类(HC)算法过程

研读教材Jp198，系统学习凝聚式层次聚类的核心方法，梳理从单个样本到合并聚类的完整算法步骤与关键逻辑。



05. 绘制并解读HC聚类树状图

通过可视化方式展示层次聚类的树状图结构，并按照要求将数据聚成5个类别，结合结果分析聚类的合理性与特征。



06. 《白话机器学习》K-means读书笔记

提炼书中关于K-means算法的通俗解读与核心案例，总结个人阅读感悟，梳理算法在实际应用中的关键点与注意事项。

簇的概念

01 感官层次

核心是“物以类聚，人以群分”。这是对簇最直观的理解：现实世界中，相似的事物天然地倾向于聚集在一起，形成可被感知的群体。

02 逻辑层次

从逻辑上定义，一个簇内部的对象彼此之间具有较高的相似度，而不同簇的对象之间存在显著的差异。这是区分不同群体的核心逻辑依据。

03 量化层次

这是聚类的数学目标。通过距离度量（如欧氏距离），使同一簇内的数据点尽可能接近，不同簇之间尽可能远离，实现数据的最优划分。



补充说明：簇在空间中可呈现圆形、带状、不规则形状等多种复杂形态，没有通用的算法能适用于所有场景。实际应用中，需根据数据的分布特征，选择合适的聚类算法来发现数据中潜在的簇结构。

类度量方法

欧式距离 (Euclidean Distance)

两点之间的直线距离，是几何空间中最直观的距离概念，反映点与点在坐标系中的绝对位置差异。

$$d = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2}$$

对数值的尺度（量纲）非常敏感，因此在使用前通常需要对数据进行标准化处理，以消除量纲影响。

余弦距离 (Cosine Distance)

衡量两个向量在方向上的差异，通过计算它们夹角的余弦值来表示相似度，而非关注向量的绝对长度。

$$\cos\theta = (A \cdot B) / (|A| |B|)$$

广泛应用于文本分析、推荐系统等领域，适合衡量文档主题、用户偏好等非数值型或高维稀疏数据的相似度。

K-means算法原理与步骤

核心定义：K-means是一种无监督的基于距离度量的划分聚类算法，通过对样本空间进行划分，将相似的对象归并到同一簇中。

优化目标：通过迭代优化策略，最小化簇内样本的距离平方和，最终使划分结果满足“同簇数据高度紧凑，不同簇数据相互分离”的状态。



01 初始化中心

从数据集中随机选取 K 个样本点，将其作为初始的聚类中心，确立算法的起点。



02 样本分配

计算每个样本点到 K 个中心的距离，遵循“最近邻原则”，将样本分配至距离最近的簇中。



03 更新中心

对每个簇内的所有样本点计算均值，将该均值向量作为新的聚类中心，让中心向簇的重心移动。



04 迭代优化

重复执行“分配-更新”的过程，直到聚类中心的变化小于设定阈值，或满足其他终止条件为止。

中心稳定：聚类中心在迭代过程中不再发生显著移动，位置趋于稳定。

分配不变：所有样本点的簇归属关系不再改变，没有对象被重新分配到其他簇。

误差收敛：簇内误差平方和（SSE）降至最小值，且后续迭代不再明显减小。

HC（层次聚类） 算法过程

工作原理： HC（Hierarchical Clustering）是一种自底向上的凝聚式聚类方法，不直接生成最终聚类结果，而是通过逐步合并相似簇，构建出完整的树状层次结构（树状图），可按需在不同层级截取得到聚类结果。

01. 初始化

将数据集中的每个样本点，均视为一个独立的、仅包含自身的初始类簇，此时类簇总数等于样本总数。

02. 寻找最近簇

根据预设的簇间距离计算规则，遍历当前所有类簇，计算两两之间的距离，找出距离最近的一对类簇。

03. 合并类簇

将上一步找到的距离最近的两个类簇合并，生成一个新的类簇，此时总类簇数减少一个。

04. 迭代终止

重复“寻找+合并”的操作，直到所有样本合并为一个大类簇，或达到预设的簇数量K时停止迭代。

单链接 (Single Linkage)

以两个类簇中距离最近的样本点对的距离，作为这两个簇的距离。该方法易形成链式结构，对异常值较敏感。

全链接 (Complete Linkage)

以两个类簇中距离最远的样本点对的距离，作为簇间距离。该方法能有效抑制链式结构，但对异常值同样敏感。

平均链接 (Average Linkage)


计算两个类簇中所有样本点对的距离平均值，作为簇间距离。该方法兼顾了整体特征，聚类结果通常更平滑稳定。

HC聚类结果图示（5类）

01. 核心图示：层次聚类树状图 (Dendrogram)
树状图直观呈现了从单个样本逐步合并为大簇的全过程，是层次聚类最经典的可视化表达形式，能够清晰反映样本间的亲疏关系与合并顺序。

02. 关键解读：“一刀切”的聚类逻辑
纵轴代表簇间的不相似度（合并距离）。通过绘制一条水平切割线，线与树状图垂直线的交点数量，即为最终划分的聚类类别数；切割线位置越高，类别越少，粒度越粗。

03. 实例分析：确定5类聚类方案
图中红色虚线（y=15）为选定的切割阈值，该线与树状图垂直线相交于5个点，据此将数据集明确划分为5个具有显著差异的聚类类别，符合分析预期。



图表：基于Ward方法生成的层次聚类树状图。不同颜色分支代表最终划分的5个类别，红色虚线清晰标记了类别划分的阈值高度，是聚类结果判定的直观依据。

《白话机器学习》K-means读书笔记

01. 核心思想：划分聚类的循环优化

K-means是典型的划分聚类算法，核心在于通过“分配”样本到最近簇心、“更新”簇心为样本均值这两个阶段反复循环，直至簇心稳定，从而优化聚类结果。

02. 算法本质：簇内紧密，簇间疏离

其目标与聚类定义高度一致：追求同一分组内的记录距离尽可能近，不同分组间的记录距离尽可能远，以此实现数据的自然分组与区分。

03. K值选择：灵活与难点并存

K值需人为事先指定，这是其灵活性所在，也是应用难点。实践中需结合业务场景知识，或借助肘部法则、轮廓系数等方法辅助确定最优K值。

04. 敏感性：受初始点与噪声影响

算法对初始聚类中心的随机选择和数据中的离散点（噪声、异常值）非常敏感，不同的初始条件可能导致截然不同的聚类结果，稳定性不足。

05. 效率与应用：简洁有效的首选

尽管处理超大规模数据时时间开销较大，但因其原理简单、易于实现且效果直观，仍是工业界和学术界处理常规聚类问题的首选算法之一。

06. 局限性：假设凸形且簇大小相近

算法基于簇是凸形、各向同性且大小相近的假设，因此无法很好地处理类别交叉、形状不规则（如环形、带状）或密度差异大的数据集。

总结



01. 聚类思维的层次递进

理解聚类可从感官直觉、逻辑归纳到量化计算三个层次深入，核心是发现数据内在的相似性与聚集规律。



02. 距离度量是分析前提

选择合适的距离度量（如欧氏距离、余弦距离）是聚类有效性的基础，需根据数据特征与分析目标灵活选取。



03. K-means：高效的划分式聚类

作为经典算法，具有高效易用的特点，但需预先指定K值，且对初始质心敏感，结果可能存在不稳定性。



04. HC算法：可解释性强的层次聚类

通过凝聚或分裂的方式生成清晰的树状层次结构，无需预设簇的数量，可解释性极佳。该算法适合分析小规模数据集，能直观呈现数据间的层级关系与嵌套结构。



05. 无监督学习的广泛应用价值

作为无监督学习的核心技术，聚类在客户分群、图像分割、异常检测、生物信息学等领域发挥着关键作用，能帮助挖掘未标注数据的潜在模式，为决策提供数据支撑。

第五次作业

姓名：王善义 学号：202321054048

作业说明



01. 整理关联选股背景知识

系统梳理关联规则核心理论，深入理解Apriori算法的原理、迭代流程及其在金融量化选股场景中的适配性与应用价值。



02. 分析数据矩阵的行与列含义

将传统的选股问题转化为经典的购物篮分析模型，精准解析数据矩阵中行与列的业务含义，构建适配关联规则挖掘的数据结构基础。



03. 使用Python运行关联规则算法


利用Python的mlxtend机器学习库，编写代码实现Apriori算法的完整运行流程，对金融行业板块数据进行挖掘，提取有效的关联规则。



04. 分析结果并指正教材概念错误

深度解读算法输出的支持度、置信度与提升度指标，并结合实证结果，严谨指正教材中关于关联规则核心概念定义与计算的典型错误。

关联选股背景知识



图示为购物篮分析热力图，展示了商品类别间的关联强度。这种分析思路可迁移至金融市场，将行业涨跌视为“交易行为”，挖掘板块间的联动规律。

01. 核心逻辑：从关联规则到Apriori算法

关联规则挖掘数据中项集间形如 $\{A\} \rightarrow \{B\}$ 的隐含关系；Apriori算法作为经典实现，利用“先验知识”剪枝，高效挖掘频繁项集，是关联分析的基石。

支持度 (Support)

衡量规则的普遍性，即项集在数据集中出现的频率，反映关联关系的基础覆盖度。

置信度 (Confidence)

衡量规则的可靠性，即条件概率 $P(B|A)$ ，反映在A发生的前提下，B发生的可能性大小。

提升度 (Lift)

衡量规则的有效性，剔除基础频率的影响。Lift > 1 表明A与B存在正相关的实际关联。

金融映射：从“商品购买”到“行业涨跌”

将股票或行业视为“商品”，价格波动视为“购买行为”，通过挖掘行业间的联动规律，识别具备领先信号的板块，为量化选股策略提供数据支撑。

数据矩阵含义解析

行：交易记录 / 股票组合

每一行代表一个独立的观测单元，通常对应特定的时间窗口（如单日交易）。在此窗口内，完整记录了市场中所有目标行业的整体表现数据。

列：行业 / 股票类别

每一列代表一个具体的研究对象，例如申万一级行业指数（银行、计算机、医药等）。列的维度清晰界定了我们分析的行业边界与范畴。

单元格：布尔型状态标记 (True/False)

单元格存储布尔值（1/0），用于标记在该行对应的时间窗口内，该列对应的行业是否出现了预设的关键行为（如当日上涨、达到阈值等）。

本质：转化为经典的“购物篮分析”问题

将“时间窗口”类比为“顾客事务”，“行业”类比为“商品”，“上涨”类比为“购买”。通过这种转化，可直接复用成熟的关联规则挖掘算法来发现行业联动规律。

Python程序运行步骤



通过Python实现关联规则挖掘，将抽象的算法理论转化为可执行的代码逻辑，从环境配置到最终可视化，形成完整的数据分析闭环。

01. 安装依赖库

使用pip安装mlxtend用于关联规则挖掘，networkx用于网络可视化。执行命令：
pip install mlxtend networkx。

02. 导入核心库

导入pandas处理交易数据，引入TransactionEncoder做格式转换，并从mlxtend中导入apriori和association_rules核心函数。

03. 数据读取与转换

读取CSV格式的原始交易数据，利用TransactionEncoder将数据转换为算法所需的One-Hot编码布尔矩阵格式。

04. 运行Apriori算法

设定合理的最小支持度(min_support)阈值，调用apriori函数扫描数据集，高效挖掘出所有满足条件的频繁项集。

05. 生成规则与可视化分析

基于频繁项集调用association_rules生成规则，筛选高置信度、高提升度的有效规则；结合networkx绘制关联网络图，直观呈现商品间的内在关联结构，辅助业务决策。

程序运行结果



01. 频繁项集挖掘

挖掘出高频共现的行业组合（如 {银行, 保险}、{计算机, 电子}），这是后续生成有效关联规则的核心数据基础，反映了行业间的基础联动性。



02. 关联规则推导

以“行业A → 行业B”的蕴含式呈现逻辑关系。例如 {银行} → {保险}，揭示了当银行板块上涨时，保险板块具有显著的跟涨倾向，体现了明确的市场传导逻辑。

支持度 0.4

规则在40%的交易日中出现，反映了规律的普遍适用性。

置信度 0.8

银行上涨时，80%的情况保险也上涨，体现规则的可靠性。


提升度 1.5

银行上涨对保险上涨有1.5倍正向促进，证明规则有效非随机。



03. 行业关联网络可视化

通过术语共现网络图直观呈现行业间的关联强度与方向，节点大小与连接疏密清晰反映了各板块在市场中的核心地位与联动紧密程度。



教材分析与错误指出

教材分析的核心价值

教材分析是验证算法实现与理论一致性的关键步骤，旨在厘清核心概念的边界，确保对数据挖掘原理的准确理解，规避实践中的认知偏差。

2		删除
3		增补
4		换用符号
5		改正上下角
6		转正
7		对调
8		转移
9		接排
10		另起段
11		上下移
12		左右移
13		排齐
14		缩进梯形
15		正图
16		加大空格
17		减小空格
18		空 1 字距
		空 $\frac{1}{2}$ 字距
		空 $\frac{1}{3}$ 字距
19		分开

校对与勘误：

参考国家标准校对符号，对教材中公式定义、参数取值等细节进行逐字核查，是发现并修正理论表述偏差的重要方法。

误区一：支持度计算的分母谬误

错误表述：将支持度分母误写为“项集总数”，混淆了数据集的统计对象。

正确定义：分母应为“总交易数”。公式： $\text{Support}(X) = (\text{包含X的事务数}) / (\text{总事务数})$ 。

误区二：置信度条件概率的前后件混淆

错误表述：误将置信度公式写为 $P(A|B)$ ，颠倒了规则推导的逻辑方向。

正确定义：应为条件概率 $P(B|A)$ 。公式： $\text{Conf}(X \rightarrow Y) = \text{Support}(X \cup Y) / \text{Support}(X)$ 。

误区三：提升度阈值的正负相关误判

错误表述：认为提升度大于0即为正相关，忽视了独立事件的基准值设定。

正确定义：提升度 > 1 才是正相关； $\text{Lift}=1$ 为独立； $\text{Lift}<1$ 则为负相关关系。

核心要点总结



关联规则：量化选股的有效工具

将市场联动的直觉转化为可量化的客观规则，突破主观判断的局限，为选股策略提供数据支撑。



数据矩阵：关联分析的核心基石

以交易或投资组合为行，行业或标的为列构建矩阵，将复杂的选股问题转化为成熟的购物篮分析模型。



Python：高效便捷的算法落地

借助 `mlxtend` 库中的 Apriori 算法实现工具，能够快速处理大规模数据，完成频繁项集挖掘与规则生成。



审慎甄别：教材中的概念性误区

在学习过程中，需仔细辨析支持度、置信度与提升度的定义边界及计算逻辑，避免因概念混淆导致分析结论偏差，建立严谨的量化分析思维框架。



回归本质：理论结合实际理性投资

历史数据呈现的关联规律不代表未来必然重复。投资决策需结合宏观环境、行业周期与公司基本面进行多维度交叉验证，坚守理性投资的基本原则。

简单线性回归作业

姓名：王善义 学号：202321054048



数据清洗与探索

处理缺失值、异常值，通过散点图与相关系数分析变量间的线性关系，奠定建模基础。



参数求解与拟合

利用最小二乘法推导回归系数，构建线性方程，通过代码实现数据拟合并绘制回归线。



模型评估与检验

使用 R^2 、MAE、MSE等指标评估拟合效果，分析残差分布以验证模型的合理性与适用性。

作业问题说明



01. 数据维度的严谨性

为什么特征矩阵 X 必须是列向量？若错误地使用行向量输入，会对矩阵运算及后续模型参数求解产生何种影响？



02. 模型性能的量化评价

如何科学评价回归结果的好坏？ R^2 （决定系数）的数值含义是什么？它如何反映模型对数据变异的解释能力？



03. 最小二乘法的手动实现

不依赖第三方库，基于矩阵运算推导并手动实现最小二乘法，求解线性回归的参数，深入理解算法的数学本质。



04. 模型参数的获取与解读

在模型 $y = b_0 + b_1 \cdot x$ 中，如何从训练结果中提取截距 b_0 和斜率 b_1 ？这两个参数的实际物理意义分别是什么？



05. 数据划分比例的敏感性分析


调整训练集与测试集的划分比例（如7:3、8:2等），观察 R^2 指标的变化趋势，分析不同比例对模型泛化能力的影响。



06. 拓展阅读与相关资料

推荐阅读《统计学习方法》中线性回归章节，以及 Scikit-learn 官方文档关于模型评估的内容，加深对理论与实践的结合理解。

Q1: X为什么必须是列向量?



矩阵维度是机器学习算法输入的核心规范。特征矩阵X的维度定义了样本与特征的映射关系，直接决定了算法运算的有效性与正确性。

01. 核心维度定义：样本与特征的映射

在机器学习中，特征矩阵X本质是 $M \times N$ 的二维矩阵。其中M代表样本数量，N代表特征数量。在本案例中，我们拥有25个样本且仅含1个自变量特征，因此X必须被构造为 25×1 的列向量结构。

02. 典型错误：行向量陷阱

若误将X处理为行向量，维度将变为(1, 25)。这会导致矩阵运算时维度不匹配，sklearn库会直接抛出ValueError，中断程序执行。

错误维度示例

```
print(X.shape) # 输出: (1, 25) →  
ERROR
```

03. 代码规范：确保二维结构

使用 `.iloc[:,0:1]` 切片而非 `.iloc[:,0]`，可确保索引结果始终为DataFrame，调用`.values`后仍保持二维数组形态，避免降维为一维。

正确写法

```
X = df.iloc[:,0:1].values  
# 输出: (25, 1) → OK
```

总结：算法库设计默认接受二维矩阵输入，单列特征必须显式保持 (样本数, 1) 的列向量结构。

Q2: 模型参数b0和b1的获取

■ 模型公式定义

线性回归的核心是寻找最佳拟合直线: $y = b_0 + b_1 \cdot x$


■ 关键属性获取

斜率 b_1 (系数):

调用模型属性 `regressor.coef_`

截距 b_0 :

调用模型属性 `regressor.intercept_`



■ 案例训练结果

计算得出系数 $b_1 = 9.91065648$, 截距 $b_0 = 2.01816004$ 。保留三位小数后, 得到关键参数:

最终拟合模型:

$$y = 2.018 + 9.911x$$

```
# 获取系数和截距
b1 = regressor.coef_; b0 = regressor.intercept_
# 格式化打印模型公式
print(f'y = {b0:.3f} + {b1[0]:.3f}x')
```


Q3: R^2 评价指标与代码实现

R^2 (决定系数) 含义

R^2 是衡量回归模型对数据拟合程度的核心指标，取值范围为 $[0, 1]$ 。其数值越接近 1，代表模型对数据的解释能力越强，拟合效果越好；若接近 0，则说明模型拟合效果较差。

模型表现结果解读

训练集 R^2 : 0.9516

测试集 R^2 : 0.9455


两个 R^2 值均接近 1 且差距很小，说明模型不仅拟合效果优异，同时具备极佳的泛化能力，未出现过拟合现象。

Python 代码实现

```
# 调用score方法计算 $R^2$ 
r2_train = reg.score(X_tr, y_tr)
r2_test = reg.score(X_te, y_te)
# 格式化打印结果，保留4位小数
print(f'Train  $R^2$ : {r2_train:.4f}')
print(f'Test  $R^2$ : {r2_test:.4f}')
```

核心结论：通过 R^2 指标验证，模型在训练集和测试集上的表现高度一致且优秀，证明了算法选择的合理性与模型构建的可靠性。

Q4: 训练测试比例对 R^2 的影响



核心调整逻辑

通过Python的`train\_test\_split`函数，修改`test\_size`参数，即可灵活控制训练集与测试集的划分比例，进而观察 R^2 指标的变化规律。



test_size = 0.2 (8:2)

训练与测试 R^2 均 ≈ 0.95 ，数值稳定且表现优异。这是目前业界最常用、最推荐的经典数据分割比例。



test_size = 0.3 (7:3)

训练数据量减少，模型有欠拟合风险；测试 R^2 值可能出现小幅波动，评估稳定性略低于8:2的比例。



test_size = 0.1 (9:1)

训练数据极充足，但测试样本过少，导致 R^2 评估结果偶然性大、极不稳定，难以反映模型真实泛化能力。

最佳实践结论与代码示例

测试集比例建议控制在0.2~0.3区间，可平衡拟合风险与评估稳定性，获得最可靠的模型表现。

```
train_test_split(X,Y,test_size=0.2,...)
```


Q5: 最小二乘法实现



核心原理：最小化误差平方和

通过最小化误差的平方和来寻找数据的最佳函数匹配，即最小化 $\sum (y_i - \hat{y}_i)^2$ ，使预测值与真实值的偏差达到最小，从而确定线性模型的参数。



关键公式：直接求解参数

斜率 b_1 :

$$\frac{\text{协方差}(x,y) / \text{方差}(x)}{\sum [(x_i - \bar{x})(y_i - \bar{y})] / \sum [(x_i - \bar{x})^2]}$$

截距 b_0 :

由均值点直接计算

$$b_0 = \bar{y} - b_1 \times \bar{x}$$



代码实现：从原理到代码

1. 计算特征x与标签y的均值($\bar{x}$, $\bar{y}$)；2. 计算协方差项(分子)与方差项(分母)；3. 代入公式求解 b_1 和 b_0 ；4. 封装为可复用的函数，完成手动实现的线性回归预测。



结果验证：对齐专业库结果

手动实现的参数 b_1 、 b_0 应与 sklearn 库中 LinearRegression 模型的 `regressor.coef_` 和 `regressor.intercept_` 输出完全一致，以此验证推导与代码的正确性。

参考资料与总结

推荐学习资料

1. 线性回归原理及Python实现

深入解析线性回归的数学推导与Sklearn库的代码实践，适合初学者上手理解算法核心逻辑。

2. 最小二乘法详解

从几何意义与代数求解两方面剖析最小二乘法，厘清误差函数最优化的核心数学思想。



数据维度规范

输入特征矩阵X必须是 $M \times N$ 的列向量形式，确保数据结构符合模型输入要求，避免维度错误。



拟合效果评价

采用 R^2 决定系数作为核心指标，该值越接近1，代表模型对数据的解释能力与拟合效果越好。



模型参数提取

训练完成后，通过coef_属性获取权重系数，intercept_属性获取截距项，完成模型参数解析。



数据集科学划分

为验证泛化能力，通常将数据按8:2或7:3的比例随机划分为训练集与测试集，保障评估客观性。



南京工业大学
NANJING TECH
UNIVERSITY

数据挖掘与机器学习

Classification algorithm

姓名：王善义

学号：202321054048

2026年4月15日

目录

CONTENTS

01 | **问题一**
Question 1

02 | **问题二**
Question 2

03 | **问题三**
Question 3

04 | **问题四**
Question 4



南京工业大学
NANJING TECH
UNIVERSITY

01

PART ONE

问题一

—
Question 1



► 观察数据集的特征，有几个属性？

该数据集共有 5 个属性，包含研发支出、管理支出、营销支出、所在州、营收 5 个维度，分别对应 R&D Spend-X1, Administration-X2, Marketing Spend-X3, State-X4, Profit-Y。

► 属性中的分类变量是什么？


数据中的分类变量为 State-X4，包含 New York、California、Florida 三个取值。

► 可视化分类变量（城市）和因变量（营收）之间的关系。

通过py来进行可视化结合了箱线图与散点图：

箱线图展示了不同州营收的整体分布情况。

- 佛罗里达州 (Florida)：营收均值最高，约 118774 美元
- 纽约州 (New York)：营收均值次之，约 113750 美元
- 加利福尼亚州 (California)：营收均值相对最低，约 103905 美元
- 散点展示了每个样本的具体营收值
- 红色标注了每个州的营收均值：





南京工业大学
NANJING TECH
UNIVERSITY

02

PART TWO

问题二

—
Question 2

► 如何把分类变量转化为onehot, 过程是什么?

提取类别

数据中的分类变量为 State-X4,
包含 New York、California、
Florida 三个取值。

填充数值

对每一行样本, 根据它原来的
州取值, 把对应新列设为 1,
另外两列设为 0

转化过程

创建新特征

为这 3 个类别分别创建新列:
State_X4_California、
State_X4_Florida、
State_X4_New York

删除原列

删除原来的State-X4字符串列,
避免重复信息



南京工業大學
NANJING TECH
UNIVERSITY

03

PART TWO

问题三

—
Question 3



► 如何评估结果？ R^2

- **R2 得分**：0.949这个结果意味着：拟合效果已经非常优秀了，说明你选的研发这些特征，对公司营收的预测能力很强。
- **模型系数**：[0.778, 0.029, 0.0347]这三个系数对应三个数值特征的影响权重：
- 研发支出的系数 0.778：研发投入每增加 1 美元，企业营收平均会增加 0.778 美元，是对营收影响最大的因素
- 营销支出的系数 0.0347：营销投入每增加 1 美元，营收平均增加 0.0347 美元
- 管理支出的系数 0.0293：管理投入每增加 1 美元，营收平均增加 0.0293 美元这也符合创业公司的业务特点：研发投入对营收的拉动作用远高于其他支出。

▼ 第4步 评估系数 R^2

```
23]: R2 = regressor.score(X,Y)
      R2
```

```
23]: 0.9490884301964866
```

```
24]: bi = regressor.coef_ # 系数（权重）
      bi
```

```
24]: array([0.77884104, 0.0293919 , 0.03471025])
```




南京工业大学
NANJING TECH
UNIVERSITY

04

PART TWO

问题四

Question 4

► 如何获得系数（属性的权重），以及截距？怎么分析这个结果？最终的数学公式应该是什么？

如何获得系数

- 执行完 regressor.fit(X_train, Y_train) 这步之后），调用模型的内置属性可以计算得到。

01

如何分析这个结果

- 每个系数都代表：在其他所有条件不变的情况下，这个特征每增加 1 单位，营收的平均变化量
- 正数代表这个特征会正向拉动营收，负数代表会拉低营收
- 系数的绝对值越大，代表这个特征对营收的影响越大

02

最终的数学公式应该是什么

$$\begin{aligned} \text{Profit} = & 50125.3438 \\ & + 0.8060 * \text{R \& D Spend} - X1 \\ & - 0.0270 * \text{Administration} - X2 \\ & + 0.0270 * \text{Marketing Spend} - X3 \\ & + 198.7888 * \text{State} - X4_Florida - \\ & 41.8870 * \text{State} - X4_New York \end{aligned}$$

03



南京工业大学
NANJING TECH
UNIVERSITY

感谢您的观看！

姓名：王善义

学号：202321054048

2026年4月16日

KNN与Logistic回归实验作业

姓名：王善义

学号：202321054048

作业说明

01 / 实验目的



掌握核心算法原理：深入理解K近邻（KNN）与Logistic回归算法的数学逻辑，能够独立完成算法的代码实现与基础调试。



分析特征工程影响：探究One-Hot编码、特征缩放等预处理手段对模型收敛速度与预测精度的具体作用，总结特征处理的关键原则。



对比与优化模型表现：对比不同分类算法在数据集上的性能差异，分析K值、训练集比例等超参数对结果的影响，并学习识别与缓解模型的过拟合现象。

02 / 数据集介绍



Social_Network_Ads 数据集

包含400条社交网络用户行为记录，聚焦用户在社交平台上的产品购买转化预测，是经典的二分类问题研究样本。



关键特征变量

涵盖用户基础属性：性别 (Gender)、年龄 (Age) 以及经济属性：预估薪资 (EstimatedSalary)，维度简洁且具有代表性。



目标标签变量

二元离散变量 Purchased（是否购买），取值为 0（未购买）和 1（已购买），用于验证分类模型的预测准确性。

实验一： 性别one-hot编码对Acc值的影响

特征使用情况	KNN 准确率	Logistic 准确率
不使用性别特征	0.9300	0.8900
使用性别one-hot编码	1.0000	1.0000
性能提升幅度	+0.07	+0.11



模型准确率显著提升

引入经过one-hot编码的性别特征后，KNN与Logistic回归模型的分类准确率均达到1.0000，实现了预测性能的完美跃升，效果极为显著。



验证性别特征的核心价值

实验数据有力证明，性别特征是该分类任务中具有关键预测作用的输入变量，对模型判断结果产生决定性影响，不可或缺。

实验二：KNN与Logistic算法效果对比

01. 算法准确率性能实测

数据集类型	KNN 模型准确率	Logistic 模型准确率
训练集 (Train Set)	1.0000	1.0000
测试集 (Test Set)	1.0000	1.0000



分类表现：完美拟合当前数据分布

在本次实验数据集上，KNN与Logistic回归模型均实现了100%的分类准确率。这表明两类算法均能精准捕捉数据特征与标签间的映射关系，完成了理想的分类任务。



算法本质：非线性适配 vs 概率可解释性

KNN作为非参数模型，对非线性可分数据适应性更强，无需假设数据分布；Logistic回归则是参数模型，能输出样本属于各类别的概率值，为决策提供明确的统计解释，二者适用场景各有侧重。

实验三：训练集比例对结果的影响

实验变量设置

本次实验通过梯度调整数据集划分比例，将测试集比例从 50% 逐步递减至 10%，对应训练集比例从 50% 逐步提升至 90%，以观测模型性能随数据分配的变化规律。

关键实验结果

1.0000

在所有测试的比例组合下，模型在测试集上的分类准确率均保持完美收敛，未出现任何波动。

数据特性洞察

数据集特征具备极强的区分度，即使仅使用 50% 的训练数据，模型也能完全捕捉核心模式，展现出极佳的学习效率与数据质量。



实践建议：尽管模型对比例不敏感，但仍推荐采用**75% 训练集 / 25% 测试集**的标准划分方式。该方案在确保模型充分学习的同时，保留了足够的独立测试样本，能更稳健地评估模型的泛化能力。

实验四：超参数K对结果的影响

K值	训练集准确率	测试集准确率
1	1.0000	1.0000
3	1.0000	1.0000
7	1.0000	1.0000
9	1.0000	1.0000

数据说明：在本次实验的数据集上，不同K值下模型的训练与测试准确率均未发生变化，表现出极强的稳定性。

实验现象：性能无显著差异

测试K=1、3、7、9等多个取值，模型的准确率始终保持为1.0。这一结果印证了当前数据集具备极高的类别区分度，使得K值的选择在此场景下对最终结果影响甚微。

理论指导：K值与模型复杂度

K值越小 → 越复杂

模型对局部样本敏感，决策边界不规则，极易产生过拟合现象。

K值越大 → 越平滑

模型趋于简单，忽略局部特征，过度泛化可能导致欠拟合，边界趋于直线。

过拟合情况分析

过拟合原理：过拟合是指模型在训练集上表现极佳，但在未见过的测试集上表现显著下降的现象，其核心成因是模型复杂度远超数据本身的规律，导致模型“死记硬背”了训练数据中的噪声与细节，而非学习到通用的模式。



实验结论：无明显过拟合现象

实验数据显示，在所有测试的K值范围内，模型在训练集与测试集上的准确率差距始终控制在0.05以内。这一结果充分表明模型具备良好的泛化能力，能够有效捕捉数据的核心规律，而非过度拟合训练数据中的随机噪声。



K=1：最高过拟合风险

此时模型复杂度达到最高，完全拟合每一个训练样本，理论上对噪声最为敏感，过拟合风险最大。



K值增大：风险逐步

模型复杂度随之降低，对局部度下降，更倾向于学习数据的过拟合风险显著减小。



K值过大：警惕欠拟合风险

当K值超出合理范围时，模型会过于简化，无法捕捉数据的关键特征与内在模式，过拟合的极端走向欠拟合的另一个极端，导致整体预测性能下降。

性别变量可视化改进

男性用户样本数据

样本总量
196人

购买转化率
33.67%

女性用户样本数据

样本总量
204人

购买转化率
37.75%



视觉编码：形状定义性别



圆形 (○)：代表男性用户群体，直观体现数据集中的基础性别维度划分。



三角形 (△)：代表女性用户群体，通过棱角区分，强化性别视觉辨识度。




视觉编码：颜色定义行为



红色 (●)：标记未发生购买行为的用户，形成视觉警示与区分。



蓝色 (●)：标记已完成购买行为的用户，突出核心转化群体特征。



多维洞察价值

通过“形状+颜色”的双重编码，可直观识别不同性别、年龄段与收入层级用户的购买行为分布密度，快速定位高转化特征人群，为精准营销策略提供可视化决策依据。

实验总结

特征工程的关键作用

实验证实性别特征对模型性能提升显著，合理的特征选择与构建是挖掘数据价值、优化模型效果的核心环节。

高质量数据的鲁棒性

数据集特征区分度高、噪声少，使得模型在不同训练集比例与K值参数调整下，始终保持稳定的输出结果。

经典算法的高效表现

KNN与Logistic回归在本数据集上均展现出极佳的适用性，分类准确率达到完美水平，验证了基础算法的有效性。

优异的模型泛化能力

模型在测试集上未出现明显过拟合现象，具备良好的泛化能力，能够可靠地迁移应用到同类数据场景中。

关键实验收获

深化理论认知
透彻理解了KNN与Logistic回归的数学原理，掌握了其在分类问题中的适用场景与核心逻辑。

掌握实验全流程
熟练运用特征预处理、超参数调优与模型评估的标准化方法，形成了完整的机器学习实验闭环思维。

锚定数据核心价值
深刻认识到高质量、高区分度的数据集是构建高性能、高鲁棒性模型的基石。

决策树算法

机器学习课程作业

姓名：王善义

学号：202321054048

实验背景与核心内容

本次实验作为机器学习课程核心实践，旨在深入理解决策树算法原理与应用。通过受控实验探究特征、预处理及算法差异对模型性能的影响，并与KNN、逻辑回归等主流算法横向对比，建立系统性的模型选择与优化认知，夯实算法实践基础。

01. 特征影响分析

以“性别”特征为变量，构建包含与剔除该特征的两组数据集，对比训练后的决策树模型准确率，量化单一特征对分类结果的具体影响权重。

02. 算法特性验证

对比原始特征与标准化特征上的模型表现，验证决策树作为基于规则的算法，是否受特征缩放操作的影响，从而理解其对数据预处理的特殊要求。

03. 算法横向对比

在统一数据集与评估标准下，将决策树与KNN、逻辑回归算法的预测准确率进行量化对比，分析不同算法在同类任务中的优劣与适用边界。



核心产出：决策树可视化呈现

生成完整的决策树结构图谱，直观展示节点分裂条件、决策路径及最终分类结果，将抽象算法逻辑转化为可解释的可视化模型。

实验一：性别因素对模型准确率的影响

01 / 实验设计思路

 **验证核心假设：**
检验“性别”特征是否对目标变量的预测具有显著贡献，是否为有效输入特征。

 **控制变量对比：**
设置A组（含性别特征）与B组（移除性别特征）对照，采用决策树分类器，以预测准确率为核心评估指标。

02 / 实验数据对比

不包含性别特征

53.00%

模型在仅使用基础特征集时，达到了基准预测水平。

包含性别特征

52.00%

引入性别特征后，准确率不升反降，出现轻微性能损耗。

03 / 结果分析与启示

 **特征贡献度分析：**
在当前数据集语境下，“性别”特征与目标变量的关联性极弱，无法为模型提供有效信息增益，反而引入了随机噪声。

 **工程实践启示：**
特征选择是建模关键。应剔除冗余、弱相关特征，以降低模型复杂度，避免过拟合风险，提升模型的泛化能力。

实验二：特征缩放对预测准确性的影响

01. 实验设计方案

实验目标：验证决策树算法是否对输入特征的量纲（Scale）敏感，探索特征预处理的必要性。

核心变量：设置对照实验组：A组使用原始特征数据，B组使用经过标准化缩放后的特征数据。

模型与指标：采用决策树分类器作为核心模型，以预测准确率（Accuracy）作为唯一的性能评估指标。

02. 实验结果对比

不进行特征缩放（实验组A）

53.00% 预测准确率

进行特征缩放（实验组B）

53.00% 预测准确率

03. 分析与核心结论

数据洞察：实验数据显示，特征缩放操作并未对模型的预测准确率产生任何影响，结果高度一致。

算法本质：决策树基于特征值的阈值进行节点分裂，而非计算样本间的欧氏距离，因此对特征的量纲变化不敏感。

实践价值：在工程实践中，使用决策树、随机森林等树基模型时，可直接跳过特征缩放步骤，有效简化预处理流程，提升建模效率。

实验三：三种算法表现对比

01 / 实验设计方案

实验目标：在统一基准数据集下，对比决策树、KNN与Logistic回归三种经典分类算法的预测性能，验证不同模型的拟合能力。

核心设定：选取预测准确率（Accuracy）作为核心评估指标，确保实验环境与参数配置一致，排除无关变量干扰。

02 / 实验结果数据

K近邻 (KNN)
非线性模型代表算法

54.0%

决策树 (DT)
可解释性强的分类器

53.0%

逻辑回归 (LR)
经典的线性分类模型

46.0%

03 / 分析与核心结论

数据洞察：非线性模型（KNN、决策树）在本次实验中表现显著优于线性模型（逻辑回归），反映出当前数据集的特征与标签间存在较强的非线性关系。

实践启示：模型选择无绝对优劣，需结合数据特性。在面对未知数据集时，应优先尝试非线性模型进行基准测试，再根据结果进行针对性调优与选择。

决策树可视化结果

01 / 可视化概述


通过可视化技术将训练好的决策树以树状结构呈现，清晰展示了模型从根节点到叶节点的完整决策路径，帮助我们深入洞察模型内部的逻辑推理过程，而非将其视为“黑盒”。

02 / 核心内容解读

树的层级结构直观呈现分类规则；内部节点标注明确的分裂条件（如“年龄 ≤ 35.5 ”）；叶节点则展示最终分类结果及对应样本分布，完整还原了每一次决策的依据。

03 / 实践应用价值

增强模型可解释性，快速识别关键影响特征；同时为模型调试提供依据，有效发现过拟合或欠拟合迹象，从而指导后续的参数优化与特征工程。



图中展示了完整的决策树层级结构，从根节点的核心特征分裂开始，层层递进直至叶节点的最终分类。这种直观的图形化表达，是决策树算法在可解释性方面优于许多复杂模型的关键所在。

实验总结



核心发现总结

特征有效性：并非所有特征都对模型有益，针对性的特征选择是提升模型效果的关键前提。

算法鲁棒性：决策树算法对特征缩放不敏感，有效简化了数据预处理流程，降低了应用门槛。

模型表现：在本实验数据集上，非线性模型（KNN、决策树）的拟合效果显著优于线性模型。



决策树算法特性归纳

核心优势：具有极高的可解释性，结果直观易懂；支持处理数值、类别等混合类型数据，无需复杂转换。

潜在局限：容易产生过拟合现象，模型稳定性较差；作为贪心算法，仅能收敛到局部最优解，而非全局最优。



多算法适用场景辨析

决策树：适合对模型解释性要求高、特征维度多样且需要快速部署的业务场景。

KNN：适用于样本量适中、决策边界不规则且噪声较小的非结构化数据分类任务。

逻辑回归：首选于特征与目标呈线性关系、需输出概率结果的经典二分类问题。



最终结论：选择合适的机器学习算法没有“万能公式”，而是一个结合数据分布特性、业务解释需求、计算成本以及模型泛化能力的多维度综合决策过程，需根据实际场景灵活权衡。



南京工业大学
NANJING TECH
UNIVERSITY

数据挖掘与机器学习

Classification algorithm

姓名：王善义

学号：202321054048

2026年4月29日

目录

CONTENTS

01 | **问题一**
Question 1

02 | **问题二**
Question 2

03 | **问题三**
Question 3

04 | **问题四**
Question 4



南京工业大学
NANJING TECH
UNIVERSITY

01


PART ONE

问题一

Question 1

► 用花萼（第一0列和第二1列）的数据来聚类

结果分析：花萼长度和花萼宽度对三类鸢尾花的区分能力较弱，聚类结果会有较多重叠，不如花瓣特征清晰。图中会看到不同类别混杂较多。



```
import pandas as pd
from sklearn.cluster import KMeans
import matplotlib.pyplot as plt

f = pd.read_excel('鸢尾花数据集.xls', header=None)
sepal = df.iloc[:,0:2].values

means_sepal = KMeans(n_clusters=3, random_state=42)
label_sepal = kmeans_sepal.fit_predict(X_sepal)

plt.scatter(X_sepal[:,0], X_sepal[:,1], c=label_sepal)
plt.scatter(kmeans_sepal.cluster_centers[:,0], kmeans_sepal.cluster_centers[:,1], marker='X', s=200)
plt.xlabel('Sepal Length')
plt.ylabel('Sepal Width')
plt.title('Sepal Feature Clustering')
plt.show()
```




南京工業大學
NANJING TECH
UNIVERSITY

02


PART TWO

问题二

—
Question 2

► 用所有数据来聚类（所有4列）

结果分析：使用全部特征后，聚类效果更好，三类鸢尾花在 PCA 投影图上几乎完全分离，说明四个特征包含了充分的区分信息



```
X_all = df.values

kmeans_all = KMeans(n_clusters=3, random_state=42)
label_all = kmeans_all.fit_predict(X_all)

from sklearn.decomposition import PCA
pca = PCA(n_components=2)
X_pca = pca.fit_transform(X_all)

plt.scatter(X_pca[:,0], X_pca[:,1], c=label_all)
plt.title('All Features Clustering (PCA Reduced)')
plt.show()
```



南京工业大学
NANJING TECH
UNIVERSITY

03


PART TWO

问题三

—
Question 3

► K改成2

结果分析：将数据强行聚为两簇，图中可以看到原本的三个品种被错分合并，影响聚类纯度。这提示选择合适的 K 值很重要。



```
kmeans_k2 = KMeans(n_clusters=2, random_state=42)
label_k2 = kmeans_k2.fit_predict(X_all)

plt.scatter(X_pca[:,0], X_pca[:,1], c=label_k2)
plt.title('K=2 Clustering Result')
plt.show()
```



南京工业大学
NANJING TECH
UNIVERSITY

04


PART TWO

问题四

Question 4

► 分析该案例，聚类的其他输出，比如：聚类中心（代码）。可视化聚类中心。

结果分析：三个中心分别代表小型花（setosa）、中型花（versicolor）、大型花（virginica）。在图中用星号标出，清晰展示各簇的“平均值”。



```
print("K=3 聚类中心: ")
print(kmeans_all.cluster_centers_)

plt.scatter(X_pca[:,0], X_pca[:,1], c=label_all)
center_pca = pca.transform(kmeans_all.cluster_centers_)
plt.scatter(center_pca[:,0], center_pca[:,1], marker='X', s=300, c='red')
plt.title('Cluster Centers Visualization')
plt.show()
```




南京工业大学
NANJING TECH
UNIVERSITY

感谢您的观看！

姓名：王善义

学号：202321054048

2026年4月29日